## Web Infrastructure

RES, Lecture 7

Olivier Liechti



HAUTE ÉCOLE D'INGÉNIERIE ET DE GESTION DU CANTON DE VAUD

www.heig-vd.ch

	Tuesday	Wednesday	Friday
30.04.2018	UDP	JS 101 / lab	JS 101 / lab
07.05.2018	Lab UDP (no class)	Lab UDP (no class)	
14.05.2018	HTTP	Challenge UDP + lab HTTP	Challenge UDP + lab HTTP
21.05.2018	Web Infra	Lab	Lab
28.05.2018	Lab	Lab	Lab
04.06.2018	Lab <del>presentations</del>	Challenge HTTP (code client/server)	Challenge HTTP (code client/server)
11.06.2018	Challenge QCM Lab presentations	Lab presentations	Lab presentations

## Systemic Qualities

### The Notion of Systemic Quality



- How do we specify the requirements of a system?
  - We always build systems to deliver some sort of "service" (web, messaging, access control, customer management, etc.).
  - We first have to specify "what" the system should do. In other words, we have to specify functional requirements.
  - We also have to specify "how" the system should behave, i.e. what qualities it should exhibit. These are the non-functional requirements.
- Non-functional requirements characterize systemic qualities, or "-ilities":
  - There are lots of different systemic qualities. Depending on the system, some are more important than others.
  - Choices made when defining the system architecture have a large impact on the systemic qualities.
  - Your life as an architect will be to deal with trade-offs in addressing conflicting systemic qualities.

## **System** Vehicle

### **Functional requirements**

Move people around

### **Non-functional requirements**

Performance
Capacity
Reliability
Cost
Aestethics
Ease of use










Different systemic qualities often create opposing forces.

Defining the "right" architecture for a system means finding the right balance between these forces.



### Some Systemic Qualities...



#### · Response time

- Measures the time required to present a result to the user
- Important for the end-user

#### Throughput

- Measures the number of requests that can be processed in a given time frame
- Important for the service provider

#### Scalability

- Measures how easy/costly it is to adapt the system in order to handle additional load
- Ideally: linear scalability. "2 x more users => 2 x more servers"

#### Availability

- Measures the percentage of time during which the system can be used
- 99% availability = average unavailability of 3.65 jours per year, i.e 1 hour and 41 minutes per week.

#### Security


#### Manageability

• Measures the ease of operating the system: how easy is it to monitor it, to detect issues, to upgrade, etc.


http://en.wikipedia.org/wiki/llities



















UP



Disk space





# Performance et scalabilité du service HTTP

## Optimiser les performances du service H D'INGÉNIERIE ET DE GESTION DE VAUD WWW.heig-vd.ch

- > Deux approches complémentaires
  - Scaling Up (scalabilité verticale)
  - Scaling Out (scalabilité horizontale)

Scale Up: "Dopez vos performances!"



 On vise à améliorer les performances d'un composant, en procédant à des optimisations et en ajoutant des ressources (CPU, mémoire, bande passante, etc.).



Scale Out:
"L'union fait la force!"


- > Scale Out
  - On vise à améliorer les performances du système global, en répartissant la charge entre plusieurs composants



## Optimiser les performances du service H D'INGÉNIERIE ET DE GESTION WWW.heig-vd.ch


#### > Références

- Sander Temme, expert performance
- Articles et présentations: http:// people.apache.org/~sctemme



### > Scale Up

- Avant d'optimiser, mesurer!
- Choisir le bon modèle de (multi-process vs. multi-thread), en fonction de la plateforme (système d'exploitation)



### > Scale Out

 Utiliser Apache en mode reverse proxy et exploiter les modules de caching.

### Caching



### Qu'est-ce qu'un "cache"

- Une zone mémoire où on peut stocker des données, que l'on pourrait (ré-)utiliser dans le futur.
- "Pourquoi recalculer quelque chose que j'ai déjà calculé il y a 5 minutes?"
- "Si je dois aller acheter une bouteille d'eau, autant acheter directement une harasse pour avoir une réserve."

### · Quels sont les problèmes liés à l'utilisation d'un cache?

- "Fraîcheur" des données: est-ce que ce que je lis dans le cache est encore une copie fidèle de l'original?
- Quelle politique définit la gestion du cache (ajouter, supprimer des données, etc.)
- Synchronisation: que se passe-t-il quand j'utilise plusieurs caches (par exemple dans un cluster)?



### Caching et HTTP




#### • Exemple:

 On considère une application web, qui permet d'accéder à des ressources stockées dans une base de données.

#### Sans cache:

Réponse


- Chaque requête fait "un long voyage" (du client à la base de données)
- Plusieurs réseaux sont traversés.
  - · Plusieurs composants doivent fournir un travail.
- Question: où pourrait-on gérer un cache, pour pouvoir réutiliser toute ou partie des données liées à la requête?



### Réponse: à tous les niveaux!



- Dans le navigateur:
  - On ne va pas télécharger le logo de CNN tous les jours!
- · Dans un proxy du côté client:
  - On ne va pas télécharger l'article du jour pour chaque utilisateur!
- · Dans un proxy du côté serveur:
  - On ne va pas recalculer la page d'accueil pour chaque visiteur!
  - Dans le serveur http (niveau de l'application web):
    - On ne va pas tout recalculer, on ne va pas chaque fois aller jusqu'à la DB.
  - Dans la base de données (on ne va pas aller jusqu'au disque)



### Caching: que dit la spécification HTTP?



- Une section entière est consacrée à ce sujet:
  - http://www.w3.org/Protocols/rfc2616/rfc2616-sec13.html#sec13
  - 26 pages!
- Modèle d'expiration (13.2)
- Modèle de validation (13.3)
- Pertinence de la mise en cache des réponses (13.4)
- Construction de réponses grâce aux caches (13.5)

### Expiration et validation



Caching would be useless if it did not significantly improve performance.

The goal of caching in HTTP/1.1 is to eliminate the need to send requests in many cases, and to eliminate the need to send full responses in many other cases.

The former reduces the number of network round-trips required for many operations; we use an "**expiration**" mechanism for this purpose (see section 13.2). The latter reduces network bandwidth requirements; we use a "**validation**" mechanism for this purpose (see section 13.3).

### Expiration et validation




#### Expiration

- Quand on reçoit une réponse, on veut déterminer combien de temps elle va rester "valide".
- Pendant ce temps, il sera possible de récupérer la représentation de la ressource dans le cache.

#### Validation

- Après expiration, on n'est pas sûr que le contenu du cache soit encore une représentation "fraîche" de la ressource.
- On peut alors procéder en 2 temps:
  - On envoie une première requête au serveur pour demander si la ressource a changé.
  - Si oui, c'est seulement dans un deuxième temps qu'on récupère la nouvelle représentation de la ressource.

- Forward Proxy
  - "Près du client" (le proxy qu'on utilise pour sortir)
  - Utilisé pour des raisons de sécurité et de performance.
- Reverse Proxy
  - "Près du serveur"
  - Utilisé pour des raisons de sécurité, de performance, de disponibilité, de scalabilité





### Disponibilité du service HTTP

### Disponibilité du service HTTP



### Objectif

 Garantir que le service HTTP de mon entreprise va être utilisable "la plus grande partie du temps".

### Causes pour lesquelles mon service pourrait être inutilisable

- Causes prévisibles: mises à jour et déploiement d'une nouvelle version (du système d'exploitation, du serveur HTTP, de l'application web, etc.)
- Causes imprévisibles: pannes matérielles, pannes de réseau, bugs dans le serveur HTTP, surcharge, attaque (e.g. denial of service), catastrophe naturelle, etc.

### Mesurer la disponibilité

- A = MTBF / (MTBF + MTTR)
- MTBF: Mean Time Between Failure (temps moyen entre 2 pannes)
- MTTR: Mean Time To Repair (temps moyen pour résoudre un problème)

### Disponibilité du service HTTP



- Taux de disponibilité: 98%
  - indisponibilité de 7.3 jours par an, soit 3 heures 22 minutes par semaine
- Taux de disponibilité: 99%
  - indisponibilité de 3.65 jours par an, soit 1 heure 41 minutes par semaine
- Taux de disponibilité: 99.9%
  - indisponibilité de 8 heures 45 min par an, soit 10 min 5 sec par semaine
- Taux de disponibilité: 99.99%
  - indisponibilité de 52.5 minutes par an, soit 1 minute par semaine
- Taux de disponibilité: 99.999%
  - indisponibilité de 5.25 minutes par an, soit 6 secondes par semaine
- Taux de disponibilité: 99.9999%
  - indisponibilité de 31.5 secondes par an, soit 0.6 secondes par semaine
  - indisponibilité de 6 minutes en 11.4 années!

### Comment augmenter la disponibilité?



- La disponibilité du système dépend de la qualité et de la fiabilité des composants du système:
  - Les spécifications des composants matériels indiquent souvent une valeur de MTBF.
  - Il sera difficile d'assurer la disponibilité d'un service si le logiciel est "buggé".
- · La disponibilité dépend également de la charge supportée par le système:
  - Un système qui se comporte bien à charge normale peut exhiber des problèmes quand un seuil est atteint (contentions).
- Ajouter de la redondance à l'intérieur du système, à différents niveaux, permet d'augmenter la disponibilité:
  - Si un composant tombe en panne, on peut "basculer" sur un composant équivalent de rechange.

### Composants qui peuvent être redondants



Switch




**Disques** 

Centre de calcul



Dear.

Serveurs



Accès Internet



Alimentations électriques


## Service redondant avec le serveur Apache (princépielle et de Gestion

#### > Architecture

- au moins 2 serveurs physiques (ou deux machines virtuelles).
- au moins 2 serveurs httpd configurés de manière identique.
- 1 répartiteur de charge.

#### > Fonctionnement

- Les requêtes HTTP sont envoyées vers le répartiteur de charge (Virtual IP address).
- Le répartiteur de charge distribue les requêtes entre les différents serveurs.
- Une politique définit les modalités de cette distribution!



#### > Solution matérielle

- Des entreprises fournissent des équipements spécialisés pour la répartition de charge.
- Ils peuvent être configurés de manière flexible.
- Ils peuvent être eux-mêmes déployés de manière à être hautement disponibles.
- Exemple: BIG-IP de F5. Voir: http://www.f5.com/solutions/resources/deployment-guides/

### > Solution logicielle

- La fonction de répartion de charge peut aussi être assurée par un logiciel installé sur un serveur "standard".
- Exemple: Apache mod\_proxy\_balancer + mod\_proxy
  - http://httpd.apache.org/docs/2.2/mod/mod\_proxy\_balancer.html
  - http://httpd.apache.org/docs/2.2/mod/mod\_proxy.html#proxypass

## HAUTE ÉCOLE D'INGÉNIERIE ET DE GESTION DU CANTON DE VAUD www.heig-vd.ch

### Affinité de session (sticky sessions) (1)

#### > Situation:

- On a besoin de haute disponibilité pour une application.
- On installe un cluster de serveurs apache.
- Un load balancer distribue les requêtes entre les instances du cluster.
- L'application gère une session (e.g. shopping cart).

#### > Problème:

 Que se passe-t-il si les requêtes d'un utilisateur arrivent vers des instances différentes du cluster?

#### > Solution:

- Le load balancer doit "reconnaître" des requêtes qui appartiennent à la même session.
- Toutes ces requêtes sont systématiquement envoyées à la même instance.





## HAUTE ÉCOLE D'INGÉNIERIE ET DE GESTION DU CANTON DE VAUD www.heig-vd.ch

### Affinité de session (sticky sessions) (2)

#### > Question:

 Comment le load balancer peut-il reconnaître les requêtes d'une même session?

#### > Solution 1:

En utilisant un cookie spécial

#### > Solution 2:

En réécrivant l'URL et en ajoutant un ID de session

#### > Solution 3:


Certains produits ont des méthodes plus sophistiquées.







## HTTP Infrastructure



### The Role of the Reverse Proxy



- An HTTP proxy that is "close" to the server
- Forwarding requests to the "appropriate" server
- A reverse proxy can also be configured as a load balancer. In this case, it distributes HTTP requests between several "equivalent" servers.
- Sticky sessions!

```
ProxyRequests Off
<Proxy *>
Order deny,allow
Allow from all
</Proxy>
```


ProxyPass /foo http://192.168.1.2:8080/bar

ProxyPassReverse /foo <a href="http://192.168.1.2:8080/bar">http://192.168.1.2:8080/bar</a>

### Availability




• What happens if a server (or server component) fails?




### Scalability



- Ability to evolve in order to sustain a bigger load, in quick and economical manner.
- Horizontal vs Vertical Scalability
- Elasticity





## Virtual Hosts

### Virtual Hosts & the Host Header



> telnet 84.16.80.79 80

GET /index.html HTTP/1.1

Host: <a href="mailto:www.wasabi-tech.com">www.wasabi-tech.com</a>

> telnet 84.16.80.79 80

GET /index.html HTTP/1.1

Host: <a href="mailto:www.otherdomain.com">www.otherdomain.com</a>

### http://httpd.apache.org/docs/2.4/vhosts/examples.html

```
# Ensure that Apache listens on port 80
Listen 80
<VirtualHost *:80>
    DocumentRoot /www/example1
    ServerName www.example.com
    # Other directives here
</VirtualHost>
<VirtualHost *:80>
    DocumentRoot /www/example2
    ServerName www.example.org
    # Other directives here
</VirtualHost>
```

#### Note

Creating virtual host configurations on your Apache server does not magically cause DNS entries to be created for those host names.

You must have the names in DNS, resolving to your IP address, or nobody else will be able to see your web site.

You can put entries in your **hosts file** for local testing, but that will work only from the machine with those hosts entries.

```
<VirtualHost *:*>
    ProxyPreserveHost On
    ProxyPass / http://192.168.111.2/
    ProxyPassReverse / http://192.168.111.2/
    ServerName hostname.example.com
</VirtualHost>
```